



# Prediksi Tumor Otak Dengan Gambar MRI (X-Ray) Menggunakan Klasifikasi *Convolutional Neural Network* (CNN)

Received 00th October 2024 Muhammad Kaisar Firdaus<sup>\*1</sup>, Syakira Tsania Muthmainnah<sup>2</sup>, Adisty Syawalda Ariyanto<sup>3</sup>, Andini Nur Izzati<sup>4</sup>, Evan Aprianto<sup>5</sup>, Saiful Haris Muhammad<sup>6</sup>

Accepted 00th October 2024

Published 00th March 20xx

Open Access

DOI: 10.35472/x0xx0000

<sup>1</sup>Program Studi Sains Data, Fakultas Sains, Institut Teknologi Sumatera

<sup>2</sup>Program Studi Sains Data, Fakultas Sains, Institut Teknologi Sumatera

<sup>3</sup>Program Studi Sains Data, Fakultas Sains, Institut Teknologi Sumatera

<sup>4</sup>Program Studi Sains Data, Fakultas Sains, Institut Teknologi Sumatera

<sup>5</sup>Program Studi Sains Data, Fakultas Sains, Institut Teknologi Sumatera

<sup>6</sup>Program Studi Sains Data, Fakultas Sains, Institut Teknologi Sumatera

\* Corresponding E-mail: [muhammad.121450135@student.itera.ac.id](mailto:muhammad.121450135@student.itera.ac.id)

**Abstract:** Brain tumors are a dangerous type of cancer that can affect people of various ages and demographics, often posing a serious threat to life. Proper medical treatment is crucial, particularly with the support of modern technology that aids in identification, diagnosis, and emergency interventions. This study employs the Convolutional Neural Network (CNN) method to identify brain tumor types using an MRI image dataset from Kaggle, consisting of 4 tumor classes: Glioma, Meningioma, No Tumor, and Pituitary, with a total of 3,264 images (2,870 training data and 394 test data). The research compares the performance of the original EfficientNetB0 model with three modified variations, incorporating additional layers of 256 neurons, ReLU activation function, Batch Normalization, and Dropout adjustments of 40–50%. The models were trained using Batch Sizes of 32–64, a 15% validation split, and 12–25 epochs, coupled with data augmentation techniques such as rotation up to 20 degrees, horizontal and vertical shifts, zooming by 20%, horizontal flipping, and pixel filling using the nearest method. The best model, the third modified model, achieved accuracy, precision, recall, and f1-score of 98%.

**Keywords:** Brain Tumor, Convolutional Neural Network, EfficientNetB0, Data Augmentation, MRI Images

**Abstrak:** Tumor otak merupakan jenis kanker berbahaya yang dapat menyerang berbagai usia dan kalangan, sering kali mengancam nyawa penderitanya. Penanganan medis yang tepat sangat diperlukan, terutama dengan bantuan teknologi modern yang mendukung identifikasi, diagnosis, dan tindakan darurat. Penelitian ini menggunakan metode *Convolutional Neural Network* (CNN) untuk mengidentifikasi jenis tumor otak berdasarkan dataset citra MRI dari Kaggle, yang terdiri dari 4 kelas tumor: Glioma, Meningioma, No Tumor, dan Pituitary, dengan total 3.264 gambar (2.870 data latih dan 394 data uji). Penelitian membandingkan kinerja EfficientNetB0 asli dan tiga variasi model yang dimodifikasi melalui penambahan layer 256 neuron, fungsi aktivasi ReLU, Batch Normalization, dan Dropout 40–50%. Model dilatih menggunakan Batch Size 32–64, validasi 15%, dan 12–25 epoch, dengan augmentasi data seperti rotasi hingga 20 derajat, pergeseran horizontal dan vertikal, zoom 20%, flip horizontal, serta pengisian piksel dengan metode nearest. Model terbaik yaitu model modifikasi ketiga mencapai akurasi, precision, recall, dan f1-score sebesar 98%.

**Keywords:** Tumor otak, Convolutional Neural Network, EfficientNetB0, Augmentasi Data, Citra MRI



## Introduction

Perkembangan teknologi kesehatan di era digital saat ini mengalami transformasi signifikan, terutama dalam bidang diagnostik penyakit kompleks seperti tumor otak. Tumor otak adalah kondisi pertumbuhan sel di otak yang berlangsung secara tidak normal, baik di dalam maupun di sekitar otak, dengan sifat yang tidak terkendali. Secara global, jumlah kasus tumor otak terus meningkat setiap tahun. Sayangnya, banyak orang cenderung mengabaikan gejala-gejala yang disebabkan oleh tumor otak [1]. Tumor, terutama yang berkembang di otak, merupakan kondisi medis yang membutuhkan perhatian khusus karena dapat mempengaruhi fungsi vital tubuh seperti kontrol motorik, memori, kemampuan kognitif tubuh, bahkan dapat menyebabkan kematian[2].

Tumor otak dikategorikan menjadi tumor primer dan tumor sekunder. Tumor otak primer muncul akibat perubahan abnormal dan tidak terkendali pada sel-sel otak itu sendiri. Sementara, tumor otak sekunder merupakan hasil penyebaran kanker dari bagian tubuh lain ke otak[3]. Pada penelitian ini menggunakan 4 kelas tumor yang akan digunakan, yaitu *Glioma*, *Meningioma*, *Pituitary* dan *No Tumor*.

*Glioma* tumor adalah jenis tumor primer yang sangat sering terjadi, sekitar 33% dari kasus tumor otak, Glioma berasal dari sel – sel glial dalam otak dimana merupakan sel jaringan yang mengelilingi dan mendukung sel saraf di otak. Hampir Setengah dari jumlah tumor otak yang diderita adalah Glioma dengan tingkat kejadian 30-80 per satu juta populasi [4].

*Meningioma* tumor adalah tumor yang berada di selaput yang melindungi otak dan saraf tulang belakang, sebagian besar jenis tumor ini cenderung tidak bersifat ganas. Gejala yang dialami pasien tumor Meningioma seperti sakit kepala, mual dan muntah, bola mata yang menonjol, tulang belakang yang menebal, perubahan perilaku, gangguan ingatan, kesulitan dalam berbicara, kejang, dan gangguan kesadaran [5].

*Pituitary* tumor merupakan salah satu tumor dengan pengidap terbesar dengan 10 – 15% dari total kejadian tumor otak. Oleh karena itu perlu pemeriksaan lebih lanjut sejak dini, pemeriksaan penunjang juga diperlukan untuk mendiagnosis gejala seperti pemeriksaan radiologi dan patologi, MRI otak dan regio sella turcia dengan irisan multiplanar tipis [6]. Sedangkan untuk kelas No. Tumor

merupakan kelas dimana tidak terdapat indikasi adanya jenis tumor berdasarkan hasil scan MRI.

Dengan bantuan teknologi, dapat dilakukan analisis identifikasi untuk melihat dan mendiagnosis penyakit pada pasien, salah satunya adalah teknologi AI yaitu Convolutional Neural Network (CNN) yang merupakan sebuah sistem yang menerapkan cara kerja dari deep learning [7]. CNN mampu menganalisis pola rumit dalam citra medis dengan akurasi yang mendekati atau bahkan melebihi kemampuan manusia, mengidentifikasi fitur tersembunyi yang mungkin terlewatkan oleh mata manusia, melakukan klasifikasi dengan kecepatan dan konsistensi yang tinggi, serta memberikan prediksi probabilitas keberadaan tumor dengan tingkat kepercayaan terukur.

Model Multilayer Perceptron (MLP) yang didesain untuk mengolah data dua dimensi merupakan awal dari pengembangan model CNN. Pada klasifikasi citra, MLP kurang cocok digunakan karena tidak menyimpan informasi spasial dari data citra dan setiap piksel dianggap fitur independen sehingga menghasilkan hasil yang kurang baik [8].

CNN mengolah data gambar MRI dengan cara mengekstraksi fitur penting dari setiap bagian gambar melalui proses konvolusi dan pooling, yang memungkinkan jaringan untuk mengenali pola unik pada setiap jenis tumor otak[9]. Dengan pendekatan ini, CNN dapat membedakan antara empat kelas tumor otak: *Glioma*, *Meningioma*, *Pituitary*, dan *No Tumor*. Proses klasifikasi dilakukan dengan mempelajari fitur visual seperti bentuk, tekstur, dan intensitas dari gambar MRI, sehingga dapat memprediksi keberadaan dan jenis tumor dengan tingkat akurasi yang tinggi. Keunggulan CNN dalam analisis data gambar menjadikannya alat yang sangat berguna dalam aplikasi medis, terutama untuk membantu ahli radiologi dan dokter dalam mendiagnosis tumor otak secara efisien dan tepat waktu[10].

Penelitian yang dilakukan HA Khan, W Juel, M Mushtaq dan MU Mushtaq (2021) melakukan klasifikasi tumor otak pada citra MRI menggunakan CNN menunjukkan bahwa hasil akurasi model sangat efektif dan memiliki tingkat kompleksitas yang sangat rendah [11]. Selanjutnya penelitian N Abiwinanda, M Hanif, ST Hesaputra, A Handayani dan TR Mengko (2019) menghasilkan model akurasi hingga 100% [12]. Kemudian, M Ali, JH Shah, MA Khan, M Alhaisoni, U Tariq, T Akram, YJ Kim, dan B Chang (2022) melakukan pendeteksian tumor otak dengan PSO dan klasifikasi CNN yang menghasilkan nilai rata-rata dadu


98,11% dan 98,25%, dan nilai rata-rata hasil segmentasi 96,30% dan 96,57% [13].

Penelitian ini diharapkan dapat membantu ahli medis sehingga memungkinkan perencanaan perawatan yang lebih baik bagi pasien.

## Method


CNN adalah jenis khusus dari Artificial Neural Network (ANN) yang menggunakan operasi matematika (algorithm) yang disebut konvolusi sebagai pengganti perkalian matriks umum di setidaknya satu lapisannya. Algoritma ini adalah pengenalan yang efektif diterapkan dalam pola pengenalan dan pengolahan citra. CNN ini mensimulasikan jaringan saraf biologis melalui jaringan bobot bersama struktur. CNN secara luas dipraktikkan di bidang komputer dalam masalah Computer Vision. Ini terdiri dari properti parameter berbagi yang mengurangi jumlah parameter yang dibutuhkan untuk model dibandingkan dengan ANN [14].

Struktur dasar CNN terdiri dari beberapa lapisan, termasuk lapisan konvolusi, lapisan pooling, dan lapisan fully connected. Lapisan konvolusi melakukan operasi konvolusi untuk mengekstraksi fitur visual, lapisan pooling melakukan operasi downsampling untuk mengurangi dimensi fitur, dan lapisan fully connected digunakan untuk klasifikasi akhir. Melalui arsitektur berlapis ini, CNN dapat mempelajari representasi data yang semakin abstrak dan kompleks pada setiap lapisan.



Gambar 2. Tahapan Proses Pada Model CNN[14]

Penerapan CNN telah menunjukkan performa yang sangat baik dalam berbagai tugas pengolahan citra, termasuk aplikasi medis seperti diagnosis tumor otak berdasarkan citra MRI.



Gambar 3. Flowchart Penelitian

Tahap pertama adalah input data, di mana dataset MRI tumor otak dimuat dari direktori atau sumber tertentu. Dataset dapat berupa gambar yang dikategorikan ke dalam folder berdasarkan kelas yang nantinya akan menjadi masukan utama dalam proses klasifikasi. Kemudian, dilakukan preprocessing data untuk mempersiapkan dataset sebelum masuk ke model. Dataset juga dibagi menjadi data training dan data testing. Selanjutnya, klasifikasi model menggunakan CNN (Convolutional Neural Network) yang terdiri dari lapisan konvolusi untuk mengekstrak fitur dari gambar, diikuti dengan lapisan pooling untuk mengurangi dimensi data, dan lapisan fully connected untuk menghasilkan output klasifikasi. Tahap terakhir adalah output, di mana model memberikan hasil berupa deteksi dan prediksi jenis tumor otak berdasarkan citra input.

Penelitian ini dilakukan variasi struktur model, seperti penambahan data augmentatif, variasi parameter pada pelatihan dan evaluasi model guna mendapatkan hasil yang optimal dan sebagai bahan pembandingan antara modifikasi yang dilakukan satu sama lain. Perubahan ini dinilai perlu dilakukan untuk menemukan kecocokan pendekatan antara dataset yang dipakai dan model yang digunakan, semakin baik model mengenali pola dari struktur dataset maka semakin baik pula hasil yang diperoleh.

### A. Data Preparation

Langkah awal pengerjaan setelah mendapatkan dataset ialah melakukan persiapan data, seperti mengimport package serta modul yang akan digunakan selama proses pengerjaan yang sudah menjadi hal umum dilakukan.

Setelah dataset diimport dilakukan perubahan ukuran pada tiap gambar, karena setiap gambar mempunyai ukuran gambar yang berbeda-beda satu sama lain maka diubah menjadi satu ukuran yaitu 150 x 150 pixel.

### B. Data Preprocessing

Pada penelitian ini, dataset pada saat awal telah dipisah antara data latih dan data uji namun disini peneliti mengacak kembali urutan di data latih dan data uji sesuai dengan label nya dengan pengacakan sebanyak 101 kali,

kemudian disimpan kedalam label X-Train dan y\_train, masing – masing dalam bentuk array numpy.

Karena menggunakan modul dari keras maka dilakukan teknik *one hot encoding* dimana mengubah label output dalam format string menjadi numerik. Teknik ini diperlukan untuk memudahkan dalam perhitungan menggunakan loss function serta format *one hot encoding* memungkinkan setiap kelas memiliki representasi yang unik dan mudah dikenali oleh algoritma optimasi.

### C. Build a Model

Penelitian ini menggunakan bantuan transfer learning yaitu *EfficientNetB0*, versi B0 adalah varian terkecil dalam *EfficientNet*, arsitektur ini mempunyai keseimbangan antara akurasi dan efisiensi komputasinya, dan salah satu pilihan populer dalam klasifikasi gambar. Pada arsitektur ini menggunakan dataset yang disediakan sebelumnya yaitu imagenet yang berisi lebih dari 14 juta gambar dengan 20.000 kelas lebih dengan memanfaatkan fitur yang sudah ada maka akan membuat waktu komputasi lebih optimal dan menambah informasi yang berguna bagi model. Dengan menggunakan bobot dari dataset imagenet model CNN sudah mempunyai pengetahuan awal mengenai fitur gambar secara umum, untuk memudahkan dalam dataset tumor yang akan digunakan maka pada arsitektur *EfficientNetB0* pada lapisan klasifikasi tidak digunakan dan hanya menggunakan lapisan konvolusional, untuk jenis inputnya sendiri menggunakan ukuran yang sama dengan dataset tumor dan untuk outputnya nanti menggunakan label dari dataset tumor. Langkah ini memudahkan proses klasifikasi dengan bantuan model yang sudah ada dengan fitur yang beragam guna meningkatkan hasil yang diinginkan.

### D. Model Training

Penelitian ini menggunakan dua variasi kode yang dimodifikasi pada parameter di setiap lapisan untuk mendapatkan hasil yang optimal. Pada pelatihan model pertama, menggunakan 237 lapisan dari arsitektur *EfficientNetB0* sebagai lapisan ekstraksi fitur, dan menambahkan 3 lapisan tambahan. Lapisan ekstraksi fitur *EfficientNetB0* memberikan fitur spasial dengan dimensi (5, 5, 1280) yang kemudian diubah menjadi vektor 1D dengan menggunakan Global Average Pooling 2D. Teknik ini berfungsi untuk mengurangi dimensi data dan mencegah terjadinya overfitting. Selain itu, peneliti juga menerapkan teknik Dropout, di mana 50% neuron secara acak dinonaktifkan selama proses pelatihan untuk membantu model belajar fitur yang lebih umum, bukan hanya pola spesifik dari data pelatihan, sehingga mencegah overfitting.

Lapisan Dense (Fully Connected) dengan aktivasi Softmax digunakan untuk klasifikasi akhir. Dalam modifikasi yang dilakukan, peneliti menambahkan 2 lapisan tambahan dengan 256 neuron, aktivasi ReLU, Batch Normalization, dan Dropout 40%. Tujuannya agar model dapat mempelajari fitur yang lebih rinci, menjaga non-linearitas, dan meningkatkan stabilitas serta generalisasi model.

Fungsi loss digunakan untuk menghitung kesalahan prediksi, dengan optimizer Adam yang menggabungkan keuntungan dari optimizer momentum dan RMSProp. Metrik akurasi digunakan untuk melacak kinerja model pada data validasi, dengan membandingkan kelas prediksi dengan label sebenarnya.

Selanjutnya, peneliti menggunakan beberapa callback function, yaitu TensorBoard untuk visualisasi proses pelatihan, ModelCheckpoint untuk menyimpan bobot terbaik model, dan ReduceLROnPlateau untuk mengurangi learning rate secara otomatis jika performa model stagnan. Pelatihan dilakukan dengan 10% data validasi, 12 iterasi, dan ukuran batch 32. Hasil pelatihan kemudian divisualisasikan dalam grafik akurasi dan loss untuk memantau perkembangan model selama pelatihan.

### E. Model Evaluation & Performance

Pada penelitian ini digunakan evaluasi *performance* model dengan *matrik* evaluasi yang diterapkan dengan akurasi, *precision*, *recall*, *F1-score*, dan *confusion matrix*.

$$(1) \quad \text{Akurasi} = \frac{\text{Jumlah Prediksi Benar}}{\text{Total Prediksi}}$$

Akurasi mengukur seberapa banyak prediksi yang benar dibandingkan dengan total prediksi. Metrik ini sering digunakan karena sederhana dan memberikan gambaran awal performa model. Namun, akurasi saja tidak cukup pada data yang tidak seimbang (*imbalanced dataset*).

$$(2) \quad \text{Precision} = \frac{\text{True Positive (TP)}}{\text{TP} + \text{False Positive (FP)}}$$

Precision digunakan untuk mengetahui seberapa akurat model dalam memprediksi kelas positif, sehingga relevan dalam kasus di mana kesalahan prediksi positif memiliki dampak besar.

$$(3) \quad \text{Recall} = \frac{\text{True Positive (TP)}}{\text{TP} + \text{False Negative (FN)}}$$

Recall penting untuk mengevaluasi kemampuan model dalam mendeteksi semua kasus positif, terutama jika konsekuensi gagal mendeteksi positif lebih signifikan.

$$(4) \quad F1 - Score = 2 * \frac{Precision * Recall}{Precision + Recall}$$

*F1-Score* merupakan rata-rata harmonis antara precision dan recall, digunakan untuk dataset tidak seimbang karena dapat memberikan keseimbangan antara keduanya[15].

		True Class	
		Positive	Negative
Predicated Class	Positive	TP	FP
	Negative	FN	TN

Gambar 4. Confusion Matrix [15]

Pada penelitian ini digunakan *confusion matrix*. *Confusion matrix* digunakan untuk mengevaluasi tingkat akurasi model dalam proses klasifikasi yang telah dilakukan. Tingkat akurasi ini mengindikasikan proporsi jumlah prediksi yang benar [16]. *Confusion matrix* membantu mengidentifikasi jenis kesalahan yang dilakukan model.

#### F. Detection & Predict


Pada tahap prediksi, gambar baru dimasukkan ke model yang telah dilatih untuk menentukan jenis tumor menghasilkan output berupa probabilitas untuk masing-masing kelas (*glioma tumor*, *no tumor*, *meningioma tumor*, atau *pituitary tumor*). Probabilitas ini menunjukkan seberapa besar kemungkinan gambar termasuk ke setiap kelas. Kelas dengan probabilitas tertinggi dipilih sebagai hasil prediksi akhir menggunakan fungsi *np.argmax()*. Hasilnya kemudian ditampilkan dalam bentuk label kelas, yang dapat digunakan untuk didiagnosa atau analisis lebih lanjut.

Tabel 1. Rincian Dataset Yang Digunakan


No.	Jenis Tumor	Data Uji	Data Latih
1	<i>Glioma</i>	100	826
2	<i>Meningioma</i>	115	822
3	<i>Pituitary</i>	105	827
4	<i>No Tumor</i>	74	395
Total Data		394	2.870

Penelitian ini menggunakan dataset dari website [www.kaggle.com](https://www.kaggle.com) berupa gambar dari citra scan x-ray MRI dengan total 3.264 gambar (2.870 data latih dan 394 data uji) dengan 4 kelas, yaitu *Glioma*, *Meningioma*, *Pituitary* dan *No. Tumor* yang ditampilkan pada Pada Tabel 1 [17].


Pada dataset yang digunakan, setiap jenis tumor memiliki jumlah data uji dan data latih yang berbeda. Untuk data uji, jumlah gambar yang digunakan adalah 100 gambar untuk *Glioma*, 115 gambar untuk *Meningioma*, 105 gambar untuk *Pituitary*, dan 74 gambar untuk *No Tumor*, dengan total 394 gambar. Sedangkan untuk data latih, digunakan 826 gambar untuk *Glioma*, 822 gambar untuk *Meningioma*, 827 gambar untuk *Pituitary*, dan 395 gambar untuk *No Tumor*, dengan total 2.870 gambar. Pembagian data ini bertujuan untuk memastikan pelatihan yang optimal pada model klasifikasi dan evaluasi yang akurat menggunakan data yang belum pernah dilihat sebelumnya.




Glioma



Meningioma



Pituitary



No Tumor

Gambar 5. Sample Data Gambar MRI pada Empat Kelas

Gambar 5 merupakan sampel data gambar yang digunakan dalam penelitian, masing – masing jenis tumor mempunyai ciri khasnya dan perbedaan yang dimana akan diidentifikasi dan ekstraksi fitur. Berikut adalah diagram alir yang digunakan dalam proses penelitian.

## Results And Discussion

### A. Prediksi dengan Algoritma CNN

Algoritma CNN berhasil diterapkan untuk klasifikasi gambar setelah melalui tahap preprocessing, di mana gambar diubah ukurannya menjadi 150 × 150 piksel untuk memastikan keseragaman input. Proses ini berjalan dengan



baik, memastikan bahwa model menerima data dengan ukuran yang konsisten. Dalam pelatihan model, digunakan 12 epoch dengan batch size 32, serta optimizer Adam dengan learning rate 0.0001. Fungsi aktivasi ReLU diterapkan pada lapisan konvolusi untuk memperkenalkan non-linearitas, sedangkan softmax digunakan pada lapisan output untuk klasifikasi multi-kelas.

Model CNN yang digunakan terdiri dari beberapa lapisan konvolusi dengan jumlah filter yang bertambah pada setiap lapisan (32, 64, 128, 256, 512 filter) untuk mengekstraksi fitur dari gambar. Setiap lapisan konvolusi diikuti dengan lapisan max pooling untuk mereduksi dimensi data. Setelah lapisan konvolusi, dilanjutkan dengan lapisan pooling untuk mengurangi dimensi data. Data yang sudah diproses kemudian di-flatten dan diteruskan ke lapisan *fully connected* untuk melakukan klasifikasi berdasarkan fitur yang sudah diekstraksi. Untuk mengurangi *overfitting*, diterapkan teknik dropout pada lapisan *fully connected*. Proses pelatihan model ini berjalan dengan baik tanpa ada kendala yang rumit.

## B. Hasil Model dan Modifikasi Model

Penelitian ini dilakukan dengan model CNN dan didapatkan di lihat performance modelnya untuk melihat seberapa baik model dapat mengklasifikasi data dengan akurasi tinggi dan error rendah yang akan menunjukkan model CNN ini efektif dan memiliki kemampuan generalisasi yang baik.

**Tabel 2.** Hasil Eksperimen Parameter Model

Batch Size	Validation Split	Layer	Dropout	train/test	Epoch	Akurasi
32	0.1	5	0.5	shuffle	12	98%
64	0.15	7	0.4	shuffle	5	89%
32	1	5	0.5	shuffle augmentation	7	84%
32	0.1	7	0.4	shuffle	12	98%

Pada **Tabel 2** diatas adalah eksperimen dari modifikasi parameter yang dilakukan, dimana pada baris pertama adalah kode awal tanpa modifikasi dan baris kedua sampai terakhir adalah kode yang sudah dimodifikasi dengan parameter yang berbeda.

Pada model awal yang tidak dimodifikasi atau model baseline menggunakan lapisan tambahan seperti *GlobalAveragePooling2D*, *Dropout (0.5)*, dan *Dense(4*,

*activation='softmax')* untuk klasifikasi. Model ini memiliki beberapa kekurangan, yaitu dengan tanpa adanya augmentasi data, model ini menghasilkan akurasi validasi yang moderat dengan stabilitas yang cukup, namun kurang mampu menggeneralisasi dataset baru. Pelatihan juga membutuhkan waktu yang lebih lama karena tidak ada mekanisme penghentian otomatis. Oleh sebab itu, dilakukan 3 percobaan model yang dimodifikasi untuk memperbaiki dan mengevaluasi kinerja model.

Pada percobaan 1, modifikasi dilakukan pada struktur model dan parameter pelatihan untuk meningkatkan performa klasifikasi tumor otak. Salah satu perubahan utama adalah penambahan lapisan Dense dengan 256 neuron dan aktivasi ReLU, yang berfungsi untuk mempelajari representasi fitur yang lebih kompleks sebelum klasifikasi. Selain itu, ditambahkan *Batch Normalization* untuk menormalkan distribusi output dari lapisan sebelumnya, sehingga mempercepat konvergensi model dan meningkatkan stabilitas selama pelatihan. Dropout rate juga disesuaikan dari 0.5 menjadi 0.4 untuk menjaga lebih banyak informasi sambil tetap mencegah overfitting. Pada tahap pelatihan, callback *Early Stopping* diimplementasikan untuk menghentikan pelatihan secara otomatis jika performa validasi tidak meningkat setelah beberapa epoch, yang mengurangi durasi pelatihan tanpa mengorbankan akurasi. Selain itu, penggunaan *ReduceR RAN Plateau* dan *Model Checkpoint* membantu mengoptimalkan proses pembelajaran dan menyimpan model terbaik.

Pada percobaan 2, model dimodifikasi dengan menggunakan beberapa lapisan tambahan seperti Global Average Pooling 2D, Dropout (rate=0.5), dan Dense(4, activation='softmax') ditambahkan untuk tugas klasifikasi tumor otak. Untuk meningkatkan generalisasi, data pelatihan diperluas dengan augmentasi (rotasi, pergeseran, zoom, flip horizontal) menggunakan ImageDataGenerator. Selain itu, berbagai callbacks seperti TensorBoard, ModelCheckpoint, ReduceLROnPlateau, dan EarlyStopping digunakan untuk memantau pelatihan, menyimpan model terbaik, serta mengatur laju pembelajaran, sehingga model dapat mencapai performa yang optimal.

Pada percobaan ke 3, model dimodifikasi dengan penambahan layer, dengan 256 neuron dipadukan dengan fungsi aktivasi ReLu, dan layer tambahan dengan fungsi Batch Normalization serta nilai dropout diperkecil menjadi 40%. perubahan ini dapat membantu model mempelajari pola pada gambar pelatihan dengan bantuan layer tambahan serta fungsi normalisasi yang membuat ekstraksi fitur lebih optimal. Fungsi aktivasi ReLu memungkinkan

model mempelajari hubungan antara neuron dengan lebih kompleks dibantu dengan penambahan neuron pada lapisan tambahan dan penggunaan dropout yang diperkecil.

**Tabel 3.** Matrik Evaluasi Model

Kode Awal Tanpa Modifikasi				
Kelas	Presisi	Recall	F1-Score	Support
0	0.99	0.97	0.98	96
1	0.98	0.98	0.98	48
2	0.96	0.99	0.97	89
3	1.00	0.99	0.99	98
Akurasi			0.98	331
Macro Average	0.98	0.98	0.98	331
Weighted Average	0.98	0.98	0.98	331
Modifikasi Ke-1				
0	0.88	0.92	0.90	96
1	0.85	0.85	0.85	48
2	0.92	0.75	0.83	89
3	0.88	0.99	0.93	98
Akurasi			0.89	331
Macro Average	0.88	0.88	0.88	331
Weighted Average	0.89	0.89	0.88	331
Modifikasi Ke-2				
0	0.76	0.95	0.84	96
1	0.87	0.98	0.92	48
2	0.96	0.55	0.70	89
3	0.87	0.94	0.90	98
Akurasi			0.84	331
Macro Average	0.86	0.85	0.84	331
Weighted Average	0.86	0.84	0.83	331
Modifikasi Ke-3				
0	0.99	0.97	0.98	96
1	0.98	0.98	0.98	48
2	0.97	0.99	0.98	89
3	1.00	1.00	1.00	98
Akurasi			0.98	331
Macro Average	0.98	0.98	0.98	331
Weighted Average	0.99	0.98	0.98	331

**Tabel 3** di atas merupakan rincian matrik evaluasi pada tiap variasi model yang digunakan, terlihat modifikasi model ke-3 mempunyai akurasi yang tinggi dan juga stabil. Dengan sedikit modifikasi namun menghasilkan akurasi yang baik variasi ini dipilih dalam hasil akhir penelitian.

## Conclusions

CNN merupakan model klasifikasi dengan data input berupa gambar, yang berguna untuk memprediksi dan mengklasifikasikan berbagai macam kelas, mulai dari pengenalan objek, identifikasi benda dan lain - lain.

Penelitian ini membuktikan bahwa model CNN dengan bantuan arsitektur dari transfer learning *EffecienNetB0* mampu prediksi jenis tumor pada gambar input yang diberikan, dengan melatih model dengan gambar - gambar yang sudah ada sebelumnya maka model mampu mempelajari ciri - ciri pada setiap jenis tumor.

Berdasarkan hasil penelitian ini, model CNN dengan modifikasi ke-3 menghasilkan akurasi dan performa terbaik dibandingkan dengan modifikasi lainnya. dimana mendapatkan hasil akurasi 98%, Recall 98%, dan F1-Score 98% dan tidak ada indikasi terjadinya overfitting pada data validasi.

## Conflicts of interest

Penelitian dan penulisan jurnal ini dilakukan untuk memenuhi kewajiban kami dalam tugas akhir semester pada mata kuliah Deep Learning di program studi Sains Data, Institut Teknologi Sumatera.

## Acknowledgements

Kami mengucapkan rasa terimakasih kepada rekan 1 tim yang membantu dalam proses pengerjaan penelitian ini sehingga bisa selesai sampai tahap ini. kami juga ingin mengucapkan rasa terimakasih kepada dosen pembimbing kami Ibu Rohmi Dyah Astuti, S.Si., M.Cs serta dosen pengampu Bapak Christyan Tamaro Nadeak, M.si, Ibu Ade Lailani, M.Si, dan Bapak Ardika Satria, M.Si yang telah membimbing serta mengarahkan kami sehingga penelitian ini dapat dilakukan.

## Reference

- [1] R. A. R, "KLASIFIKASI TUMOR OTAK MENGGUNAKAN CONVOLUTIONAL NEURAL NETWORK DENGAN ARSITEKTUR EFFICIENTNET-B3," *JUST IT*, p. 56, 3 may 2021.
- [2] F. Citra, F. Indriyani, and I. R. Rahadjeng, "Klasifikasi Tumor Otak Berbasis Magnetic Resonance Imaging Menggunakan Algoritma Convolutional Neural Network," *Digital Transformation Technology (Digitech)*, vol. 3, no. 2, pp. 918, Jan. 2024. [Online]. Available: <https://doi.org/10.47709/digitech.v3i2.3469>.
- [3] V. Essianda, A. D. Indrasari, P. Widyastuti, T. Syahla, and R. Rohadi, "Brain Tumor: Molecular Biology, Pathophysiology, and Clinical Symptoms," *Journal of Brain Tumors*, vol. 23, no. 4, pp. ---, Oct.–Dec. 2023, doi: 10.29303/jbt.v23i4.5585.

- [4] S. Saluja, M. C. Trivedi, and A. Saha, "Deep CNNs for glioma grading on conventional MRIs: Performance analysis, challenges, and future directions," *Mathematical Biosciences and Engineering*, vol. 21, no. 4, pp. 5250–5282, Mar. 2024. DOI: 10.3934/mbe.2024232.
- [5] A. Muis, Sunardi, and A. Yudhana, "Medical image classification of brain tumor using convolutional neural network algorithm," *Jurnal Infotel*, vol. 15, no. 3, pp. 227–232, Aug. 2023. DOI: 10.20895/infotel.v15i3.964.
- [6] M. M. Badža and M. C. Barjaktarović, "Classification of brain tumors from MRI images using a convolutional neural network," *Applied Sciences*, vol. 10, no. 6, p. 1999, Mar. 2020. DOI: 10.3390/app10061999.
- [7] F. M. Qotrunnada and P. H. Utomo, "Metode Convolutional Neural Network untuk Klasifikasi Wajah Bermasker," *PRISMA: Prosiding Seminar Nasional Matematika*, vol. 5, pp. 799–807, 2022. [Online]. Available: <https://journal.unnes.ac.id/siu/index.php/prisma/>.
- [8] I Wayan Suartika E. P., Arya Yudhi Wijaya, and Rully Soelaiman, "Klasifikasi Citra Menggunakan Convolutional Neural Network (CNN) pada Caltech 101," *JURNAL TEKNIK ITS*, vol. 5, no. 1, pp. A65-A69, 2016.
- [9] D. Husen, "Klasifikasi Citra MRI Tumor Otak Menggunakan Metode Convolutional Neural Network," *Bit-Tech (Binary Digital - Technology)*, vol. 7, no. 1, pp. xx–xx, Agustus 2024. [Online]. Available: <http://jurnal.kdi.or.id/index.php/bt>. doi: 10.32877/bt.v7i1.1576
- [10] A. B. Abdusalomov, M. Mukhiddinov, and T. K. Whangbo, "Brain Tumor Detection Based on Deep Learning Approaches and Magnetic Resonance Imaging," *\*Cancers\**, vol. 15, no. 16, p. 4172, 2023. [Online]. Available: <https://doi.org/10.3390/cancers15164172>
- [11] N. Abiwinanda, M. Hanif, S. T. Hesaputra, A. Handayani, dan T. R. Mengko, "Brain tumor classification using convolutional neural network," *IFMBE Proceedings*, vol. 68/1, 2019, doi: 10.1007/978-981-10-9035-6\_33.
- [12] H. A. Khan, W. Juel, M. Mushtaq, dan M. U. Mushtaq, "Brain tumor classification in MRI image using convolutional neural network," *SSRN*, 2021. [Online]. Tersedia di: <https://papers.ssrn.com>.
- [13] M. Ali, J. H. Shah, M. A. Khan, M. Alhaisoni, U. Tariq, T. Akram, Y. J. Kim, dan B. Chang, "Brain tumor detection and classification using PSO and convolutional neural network," *ResearchGate*, 2022. [Online]. Tersedia di: <https://www.researchgate.net>.
- [14] H. Fakhri, T. Badriyah, I. Syarif, R. Sigit, P. Elektronika Negeri Surabaya, and J. Raya, "Klasifikasi Tumor Otak Menggunakan Convolutional Neural Network," vol. 9, no. 1, p. 2024, [Online].
- [15] Y. Heryadi and E. Miranda, "Land Cover Classification Based on Sentinel-2 Satellite Imagery Using Convolutional Neural Network Model: A Case Study in Semarang Area, Indonesia," in *Intelligent Information and Database Systems: Recent Developments*, M. Huk et al., Eds. Springer Nature Switzerland AG, 2020, Studies in Computational Intelligence, vol. 830, pp. 195–206. DOI: 10.1007/978-3-030-14132-5\_15.
- [16] R. Nurhidayat and K. E. Dewi, "Penerapan algoritma K-Nearest Neighbor dan fitur ekstraksi N-Gram dalam analisis sentimen berbasis aspek," *KOMPUTA: Jurnal Ilmiah Komputer dan Informatika*, vol. 12, no. 1, pp. 91-96, Apr. 2023.
- [17] Sartaj Bhuvaji, *Brain Tumor Classification MRI Dataset*, Kaggle, 2020. [Online]. Available: <https://www.kaggle.com/datasets/sartaibhuvaji/brain-tumor-classification-mri/data>.